

Manuel d'Utilisation

CERVARENT AI

Plateforme de Recherche Documentaire Augmentée par Intelligence Artificielle
(RAG Agentique)




Figure 1: Logo officiel de la plateforme CERVARENT AI

Document rédigé dans le cadre d'un projet de fin d'études
présentant l'installation, la configuration et l'utilisation
complète de la plateforme.

Remerciements

Ce manuel accompagne le développement de la plateforme **CERVARENT AI**, réalisée dans le cadre d'un projet de fin d'études. Nous tenons à remercier l'ensemble des personnes ayant contribué, de près ou de loin, à l'aboutissement de ce projet : encadrants académiques, relecteurs et utilisateurs testeurs dont les retours ont permis d'améliorer l'ergonomie et la fiabilité de l'application.

Ce document a pour vocation d'accompagner tout nouvel utilisateur — technique ou non — dans la prise en main complète de la plateforme, depuis son installation jusqu'à son usage quotidien.

Table des matières

Remerciements	1
1 Présentation générale	2
1.1 Présentation du projet	2
1.2 Qu'est-ce que le RAG ?	2
1.3 Objectifs de la plateforme	2
1.4 Public cible	2
1.5 Fonctionnalités principales	3
2 Prérequis	4
2.1 Matériel	4
2.2 Logiciels requis	4
2.3 Configuration minimale	4
2.4 Navigateurs compatibles	4
3 Installation	6
3.1 Vue d'ensemble	6
3.2 Base de données PostgreSQL / Supabase	6
3.3 Configuration Supabase	6
3.4 Variables d'environnement et fichier de configuration	6
3.5 Installation et compilation du backend	7
3.6 Installation et lancement du frontend	7
3.7 Premier lancement	7
4 Authentification	8
4.1 Principe général	8
4.2 Création de compte	8
4.3 Connexion	8
4.4 Déconnexion	8
4.5 Gestion des rôles	9
4.6 Réinitialisation du mot de passe	9
5 Présentation complète de l'interface	10
5.1 Barre de navigation principale	10
5.2 Page d'accueil	10
5.3 Page « Publications »	10
5.3.1 Rangée de statistiques	10
5.3.2 Panneau de recherche augmentée	10
5.3.3 Bibliothèque des publications	11
5.3.4 Tableau de la bibliothèque documentaire	11
5.3.5 Panneau d'upload	11
5.4 Espace de discussion (chat RAG)	11
5.4.1 Barre latérale de conversations	12
5.4.2 Fenêtre de discussion	12
5.4.3 Carte de source	12

5.4.4	Fenêtre de prévisualisation de document	12
5.5	Pages d'authentification	13
5.6	Pages secondaires	13
6	Guide d'utilisation pas à pas	14
6.1	Se connecter	14
6.2	Naviguer dans l'application	14
6.3	Ajouter (<i>upload</i>) un document	14
6.4	Indexation	14
6.5	Rechercher et poser une question	14
6.6	Consulter les sources d'une réponse	14
6.7	Télécharger un document	14
6.8	Prévisualiser un document	15
6.9	Gérer son profil	15
6.10	Consulter l'historique des conversations	15
6.11	Administration	15
7	Fonctionnement du RAG	16
7.1	Vue d'ensemble du pipeline	16
7.2	Étape 1 : Upload et extraction du texte	16
7.3	Étape 2 : Découpage en segments (<i>chunking</i>)	16
7.4	Étape 3 : Vectorisation (<i>embeddings</i>)	16
7.5	Étape 4 : Indexation	16
7.6	Étape 5 : Recherche vectorielle	17
7.7	Étape 6 : Génération de la réponse	17
7.8	Score de pertinence affiché	17
8	Messages système	18
8.1	Messages de succès	18
8.2	Messages d'erreur	18
8.3	Messages de validation	18
8.4	Messages / indicateurs de chargement	18
9	Bonnes pratiques	19
9.1	Conseils d'utilisation	19
9.2	Sécurité	19
9.3	Gestion des documents	19
9.4	Gestion des comptes	19
10	Dépannage	20
10.1	Impossible de se connecter	20
10.2	Erreur PostgreSQL	20
10.3	Erreur Supabase (Storage)	20
10.4	Erreur d'upload de document	20
10.5	Erreur liée à l'IA (Mistral)	20
10.6	Erreur d'appel API (404 / 401 / 500)	21
10.7	Erreur côté React (frontend)	21
10.8	Erreur côté Spring Boot (backend)	21
10.9	Docker	21
A	Glossaire	22
B	Liste des acronymes	23
C	Architecture simplifiée	24

Table des figures

- 1 Logo officiel de la plateforme CERVARENT AI 1
- 3.1 Schéma récapitulatif des étapes d’installation 6
- 3.2 Terminal affichant le démarrage réussi du backend et du frontend 7
- 4.1 Formulaire de création de compte 8
- 4.2 Formulaire de connexion 8
- 5.1 Barre de navigation principale 10
- 5.2 Page d’accueil 10
- 5.3 Panneau de recherche augmentée par IA 11
- 5.4 Panneau d’upload de documents 11
- 5.5 Barre latérale des conversations (dépliée et repliée) 12
- 5.6 Fenêtre de discussion avec une réponse et ses sources 12
- 5.7 Fenêtre de prévisualisation d’un document PDF 13
- 7.1 Schéma du pipeline RAG complet, de l’upload à la réponse 16
- C.1 Schéma d’architecture simplifiée (Frontend React – Backend Spring Boot – PostgreSQL/pgvector – Supabase Storage – API Mistral AI) 24

Liste des tableaux

- 1.1 Fonctionnalités principales de CERVARENT AI 3
- 2.1 Configuration matérielle recommandée pour le poste de développement 4
- 2.2 Logiciels et versions requises 4
- 3.1 Principales propriétés de configuration du backend 6
- 5.1 Colonnes du tableau de la bibliothèque documentaire 11
- B.1 Liste des acronymes utilisés dans ce manuel 23
- C.1 Rôle de chaque composant de l’architecture 24

Chapitre 1

Présentation générale

1.1 Présentation du projet

CERVARENT AI est une plateforme web de recherche documentaire augmentée par intelligence artificielle, développée pour le compte du *Centre d'Études, de Recherche et de Valorisation* (CERVARENT). Elle permet à ses utilisateurs d'indexer des documents scientifiques (publications, rapports, articles) et d'interroger leur contenu en langage naturel via un assistant conversationnel, plutôt que de devoir parcourir manuellement chaque document.

La plateforme repose sur une architecture applicative en trois couches :

- un **frontend** développé avec **React** (TypeScript), offrant une interface de discussion inspirée des assistants IA modernes ;
- un **backend** développé avec **Spring Boot** (Java), exposant une API REST sécurisée et orchestrant le pipeline RAG ;
- une base de données **PostgreSQL**, hébergée sur **Supabase**, enrichie de l'extension **pgvector** pour la recherche vectorielle, et couplée à **Supabase Storage** pour la conservation des documents originaux.

1.2 Qu'est-ce que le RAG ?

Le sigle **RAG** signifie *Retrieval-Augmented Generation* (génération augmentée par récupération). Il s'agit d'une architecture combinant :

1. une **recherche documentaire** : à partir de la question posée, le système retrouve automatiquement les passages de documents les plus pertinents parmi ceux déjà indexés ;
2. une **génération de réponse** : ces passages sont transmis à un grand modèle de langage (LLM), chargé de rédiger une réponse naturelle et sourcée, en s'appuyant *exclusivement* sur le contenu retrouvé.

Cette approche évite deux écueils classiques des assistants IA génériques : l'absence de connaissance des documents propres à l'organisation, et le risque d'invention d'informations (*hallucinations*), puisque la réponse est systématiquement ancrée dans des extraits réels. Le fonctionnement détaillé du pipeline RAG de CERVARENT AI est décrit au chapitre 7.

1.3 Objectifs de la plateforme

- Centraliser les publications et documents de recherche du CERVARENT dans une base documentaire unique et interrogeable.
- Permettre une recherche d'information rapide, en langage naturel, sans connaissance préalable du contenu exact des documents.
- Garantir la traçabilité des réponses générées, en citant systématiquement les documents sources utilisés.
- Offrir un accès sécurisé, personnel et historisé (conversations, bibliothèque documentaire) à chaque utilisateur.

1.4 Public cible

La plateforme s'adresse principalement :

- aux **chercheurs et enseignants-chercheurs** souhaitant retrouver rapidement une information au sein de leurs publications ;
- aux **doctorants et étudiants** en phase de recherche bibliographique ;

- à toute personne du centre CERVARENT ayant besoin d'interroger la base documentaire indexée, sans compétence technique particulière.

1.5 Fonctionnalités principales

Le tableau 1.1 résume les fonctionnalités actuellement disponibles dans la plateforme, détaillées chapitre par chapitre dans la suite de ce manuel.

Table 1.1: Fonctionnalités principales de CERVARENT AI

Domaine	Fonctionnalités
Authentification	Création de compte, connexion, déconnexion, session sécurisée par jeton JWT
Gestion documentaire	Upload de documents (PDF, DOCX, TXT), indexation automatique, bibliothèque consultable
Consultation	Téléchargement du document original, prévisualisation intégrée (PDF, DOCX, TXT, images)
Recherche augmentée	Question en langage naturel, réponse générée par IA avec citation des sources
Conversation	Historique de conversations, épinglage, renommage, suppression, régénération de réponse
Retour utilisateur	Évaluation d'une réponse (avis positif / négatif)
Interface	Sidebar rétractable, thème clair/sombre, profil utilisateur avec avatar

Chapitre 2

Prérequis

Ce chapitre liste l'ensemble des éléments nécessaires avant de procéder à l'installation de la plateforme, décrite au chapitre 3.

2.1 Matériel

Aucune exigence matérielle spécifique n'est imposée par l'application elle-même : le backend et la base de données pouvant être hébergés dans le cloud (Supabase), un poste de développement standard suffit pour exécuter le projet en local.

Table 2.1: Configuration matérielle recommandée pour le poste de développement

Composant	Recommandation
Processeur	Double cœur ou plus
Mémoire vive (RAM)	8 Go minimum (Java + Node.js simultanés)
Espace disque	2 Go libres (dépendances Maven et npm incluses)
Connexion réseau	Requise (accès à Supabase et à l'API Mistral AI)

2.2 Logiciels requis

Table 2.2: Logiciels et versions requises

Logiciel	Version	Rôle
Java (JDK)	17 ou supérieur	Exécution du backend Spring Boot
Maven	Fourni via <code>./mvnw</code>	Compilation et dépendances backend
Node.js	18 ou supérieur	Exécution des outils frontend (Vite)
npm	Fourni avec Node.js	Gestion des dépendances frontend
Compte Supabase	—	Base PostgreSQL + pgvector + Storage
Clé API Mistral AI	—	Embeddings et génération de réponses

Remarque. Le projet ne nécessite *aucune installation locale de PostgreSQL* : la base de données est hébergée par Supabase, un service cloud proposant une offre gratuite suffisante pour ce projet.

2.3 Configuration minimale

- Un compte Supabase actif, avec un projet créé et l'extension **pgvector** activée.
- Une clé d'API valide sur la plateforme Mistral AI (console <https://console.mistral.ai>), utilisée pour les embeddings (modèle **mistral-embed**) et la génération de réponses (modèle **mistral-medium**).
- Les ports 8087 (backend) et 5173 (frontend en développement) disponibles sur la machine locale.

2.4 Navigateurs compatibles

L'interface est une application web standard (HTML5/CSS3/JavaScript) sans dépendance à un plugin propriétaire. Elle est compatible avec les navigateurs modernes suivants, dans leurs versions récentes :

- Google Chrome ;
- Mozilla Firefox ;
- Microsoft Edge (basé sur Chromium) ;
- Apple Safari.

Attention. L'utilisation d'un navigateur obsolète, ne supportant pas les requêtes *Server-Sent Events* (utilisées pour l'affichage progressif des réponses de l'IA), peut entraîner un affichage incorrect du chat.

Chapitre 3

Installation

3.1 Vue d'ensemble

L'installation se déroule en quatre grandes étapes, résumées à la figure 3.1 : préparation de la base de données, configuration du backend, configuration du frontend, puis lancement des deux serveurs.




Figure 3.1: Schéma récapitulatif des étapes d'installation

3.2 Base de données PostgreSQL / Supabase

1. Créer un projet PostgreSQL, par exemple via Supabase (<https://supabase.com>).
2. Dans l'éditeur SQL du projet, exécuter l'intégralité du fichier `schema.sql` fourni à la racine du projet backend. Ce script crée les quatre tables nécessaires : `document_chunks`, `uploaded_files`, `users` et `message_feedback`, ainsi que les index de recherche vectorielle.
3. Créer, dans le module *Storage* de Supabase, un bucket destiné à recevoir les documents originaux (par exemple nommé `documents`).

Remarque. Le script `schema.sql` peut être exécuté sans risque sur une base déjà existante : les instructions d'ajout de colonnes utilisent la clause `ADD COLUMN IF NOT EXISTS`, qui ne modifie pas les données déjà présentes.

3.3 Configuration Supabase

Le bucket de stockage peut rester **privé** : le backend génère des liens d'accès temporaires (URLs signées) pour le téléchargement et la prévisualisation des documents, sans jamais exposer la clé d'administration au frontend.

3.4 Variables d'environnement et fichier de configuration

La configuration du backend se fait dans le fichier `src/main/resources/application.properties`. Les principales propriétés à renseigner sont listées au tableau 3.1.

Table 3.1: Principales propriétés de configuration du backend

Propriété	Description
<code>spring.datasource.url</code>	URL de connexion JDBC à la base PostgreSQL
<code>spring.datasource.username</code> <code>/ password</code>	Identifiants de connexion à la base
<code>spring.ai.mistralai.api-key</code>	Clé d'API Mistral AI
<code>app.jwt.secret</code>	Clé secrète de signature des jetons JWT
<code>app.jwt.expiration-ms</code>	Durée de validité d'une session (24h par défaut)
<code>app.rag.max-distance-threshold</code>	Seuil de pertinence de la recherche vectorielle
<code>supabase.url</code>	URL du projet Supabase
<code>supabase.service-role-key</code>	Clé d'administration Supabase Storage
<code>supabase.storage.bucket</code>	Nom du bucket de stockage des documents

Sécurité. Les clés d'API et mots de passe ne doivent *jamaïs* être partagés ou publiés dans un dépôt de code public. Il est recommandé d'utiliser des variables d'environnement ou un fichier ignoré par le système de gestion de version. Voir également le chapitre 9.

3.5 Installation et compilation du backend

1. Se placer à la racine du projet backend (dossier contenant `pom.xml`).
2. Lancer la compilation et le démarrage du serveur :

```
cd RAG-ARGENTIQUE
./mvnw spring-boot:run
```

3. Le serveur démarre par défaut sur le port 8087. Sa disponibilité peut être vérifiée avec la commande suivante :

```
curl http://localhost:8087/api/rag/health
```

3.6 Installation et lancement du frontend

1. Se placer dans le dossier du frontend :

```
cd RAG-ARGENTIQUE/cervarent-rag-frontend
```

2. Installer les dépendances puis lancer le serveur de développement :

```
npm install
npm run dev
```

3. L'application est alors accessible depuis un navigateur à l'adresse <http://localhost:5173>. En développement, les appels à l'API (préfixe `/api`) sont automatiquement redirigés vers le backend local.

3.7 Premier lancement

1. Ouvrir <http://localhost:5173> dans un navigateur.
2. Créer un compte utilisateur (voir chapitre 4).
3. Se rendre dans la rubrique *Publications* pour indexer un premier document.
4. Ouvrir l'espace de discussion et poser une première question : la réponse générée doit citer le document indexé comme source.

Emplacement de capture d'écran

```
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
INSÉRER ICI LA CAPTURE D'ÉCRAN : Terminal affichant le démarrage réussi du
                                backend et du frontend
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
```

Figure 3.2: Terminal affichant le démarrage réussi du backend et du frontend

Chapitre 4

Authentification

L'accès à l'ensemble des fonctionnalités de recherche et de gestion documentaire de CERVARENT AI nécessite un compte utilisateur. Ce chapitre décrit le fonctionnement complet du module d'authentification.

4.1 Principe général

L'authentification repose sur un couple *nom d'utilisateur / mot de passe*. Le mot de passe n'est jamais stocké en clair : il est haché avec l'algorithme **BCrypt** avant son enregistrement en base de données. Une fois authentifié, l'utilisateur reçoit un **jeton JWT** (JSON Web Token), valable 24 heures, automatiquement joint à chaque requête envoyée au serveur. Toute route de l'application liée au RAG est protégée : un visiteur non connecté est automatiquement redirigé vers l'écran de connexion.

4.2 Création de compte

1. Depuis l'écran de connexion, cliquer sur le lien « *Pas encore de compte ? Créer un compte* ».
2. Renseigner un nom d'utilisateur et un mot de passe dans le formulaire d'inscription.
3. Valider le formulaire : un compte est créé et l'utilisateur est automatiquement connecté.




Figure 4.1: Formulaire de création de compte

Message d'erreur. Si le nom d'utilisateur choisi est déjà utilisé, le serveur renvoie le message : « *Ce nom d'utilisateur est déjà pris.* » Il convient alors de choisir un autre identifiant.

4.3 Connexion

1. Sur l'écran de connexion, saisir le nom d'utilisateur et le mot de passe associés au compte.
2. Cliquer sur le bouton « *Se connecter* ».
3. En cas de succès, l'utilisateur est redirigé vers l'espace de discussion (/chat).




Figure 4.2: Formulaire de connexion

Message d'erreur. Des identifiants incorrects renvoient le message : « *Identifiants incorrects.* » Aucune information n'est donnée sur l'existence ou non du compte, pour des raisons de sécurité.

4.4 Déconnexion

La déconnexion est accessible à tout moment depuis le profil utilisateur, situé en bas de la barre latérale de conversations (voir section 5.4.1), via l'icône dédiée. Elle invalide la session côté navigateur (suppression du jeton JWT local) et ramène l'utilisateur à l'écran de connexion.

4.5 Gestion des rôles

Fonctionnalité absente à ce jour. Dans sa version actuelle, la plateforme ne distingue *aucun rôle* entre les utilisateurs (pas de compte « administrateur » séparé) : tout utilisateur authentifié dispose des mêmes droits d'accès aux fonctionnalités de recherche, d'upload et de gestion documentaire. Ce choix, volontaire, simplifie le modèle de sécurité pour l'usage actuel du projet.

4.6 Réinitialisation du mot de passe

Fonctionnalité absente à ce jour. La réinitialisation de mot de passe (« mot de passe oublié ») n'est pas implémentée dans la version actuelle de la plateforme, celle-ci nécessitant l'intégration d'un service tiers d'envoi d'e-mails. Elle est identifiée comme piste d'évolution possible (voir annexes).

Chapitre 5

Présentation complète de l'interface

Ce chapitre décrit, écran par écran, l'ensemble des éléments visuels de l'application : menus, boutons, icônes, formulaires, tableaux et fenêtres de dialogue.

5.1 Barre de navigation principale

Présente sur les pages publiques du site (accueil, publications, contact, etc.), la barre de navigation comprend :

- le **logo et le nom** « CERVARENT » (sous-titre : « Centre de recherche »), à gauche, ramenant à la page d'accueil ;
- un **menu de liens** : *Accueil, Axes & Unités, Membres, Publications, Actualités, À propos*, le lien de la page active étant mis en évidence ;
- à droite, un **bouton de bascule de thème** (icône soleil/lune) permettant de passer de l'affichage clair à l'affichage sombre et inversement ;
- un **bouton de connexion** ou, si l'utilisateur est déjà connecté, un accès direct à l'espace de discussion.




Figure 5.1: Barre de navigation principale

5.2 Page d'accueil

La page d'accueil (/) présente la vitrine publique du centre CERVARENT et met en avant un message de bienvenue personnalisé pour l'utilisateur connecté, ainsi qu'un accès rapide à l'espace de recherche augmentée.




Figure 5.2: Page d'accueil

5.3 Page « Publications »

Accessible via le menu *Publications*, cette page rassemble trois zones fonctionnelles principales.

5.3.1 Rangée de statistiques

En haut de page, une rangée de cartes affiche des indicateurs synthétiques (par exemple le nombre total de publications indexées), calculés à partir des documents disponibles.

5.3.2 Panneau de recherche augmentée

Un formulaire de question directe vers l'IA, avec :

- un champ de saisie de question, accompagné de trois exemples de questions cliquables ;
- un sélecteur du nombre de sources à considérer (*topK*) ;

- un bouton d'envoi (icône représentant un avion en papier) ;
- l'affichage de la réponse générée, des sources utilisées et du temps de traitement en millisecondes.




Figure 5.3: Panneau de recherche augmentée par IA

5.3.3 Bibliothèque des publications

Une liste de cartes, une par document indexé, affichant :

- une **icône de document** ;
- le **titre** du document et sa **source** ;
- un **extrait** du contenu indexé ;
- le **nombre de segments** (*chunks*) associés, précédé d'une icône « dièse ».

5.3.4 Tableau de la bibliothèque documentaire

Un tableau détaillé liste chaque document indexé, avec les colonnes suivantes (tableau 5.1).

Table 5.1: Colonnes du tableau de la bibliothèque documentaire

Colonne	Contenu
Document	Titre du document (cliquable : ouvre la prévisualisation)
Segments	Nombre de <i>chunks</i> indexés pour ce document
Taille	Taille totale du contenu extrait (en caractères)
Ajouté le	Date d'indexation du document
Actions	Icônes : <i>œil</i> (prévisualiser), <i>flèche vers le bas</i> (télécharger), <i>corbeille</i> (supprimer)

5.3.5 Panneau d'upload

Situé en bas de la bibliothèque, ce panneau permet d'ajouter un nouveau document :

- un **sélecteur de mode de traitement** : *Réfléchi* (synchrone — la page attend la fin complète du traitement) ou *Instantané* (asynchrone — le traitement se poursuit en arrière-plan, avec suivi de progression page par page pour les PDF) ;
- une **zone de dépôt de fichier** (glisser-déposer ou clic), acceptant les formats *.pdf*, *.txt* et *.docx*, jusqu'à 20 Mo ;
- un **indicateur de progression** pendant le traitement ;
- un **message de résultat** (succès ou échec) une fois le traitement terminé.




Figure 5.4: Panneau d'upload de documents

5.4 Espace de discussion (chat RAG)

Accessible depuis la barre de navigation une fois connecté, cet espace (route */chat*) constitue le cœur applicatif de la plateforme. Il se compose d'une barre latérale de conversations et d'une fenêtre de

discussion.

5.4.1 Barre latérale de conversations

- un **bouton de repli/déplioement** (icône panneau latéral), animant l'ouverture et la fermeture de la barre, dont l'état est mémorisé d'une session à l'autre ;
- un **bouton « Nouvelle conversation »** ;
- un **champ de recherche** dans l'historique des conversations ;
- les **groupes de conversations** : « Épinglées », puis regroupement par période (aujourd'hui, hier, cette semaine, plus ancien) ;
- pour chaque conversation : titre, icônes d'action au survol (*épingler / désépingler, renommer, supprimer*) ;
- en bas de la barre, le **profil utilisateur** : avatar généré automatiquement (initiales sur fond coloré), nom d'utilisateur, et bouton de déconnexion.




Figure 5.5: Barre latérale des conversations (dépliée et repliée)

5.4.2 Fenêtre de discussion

- l'historique des messages, alternant messages de l'utilisateur et réponses de l'assistant (icônes distinctes : silhouette pour l'utilisateur, robot pour l'assistant) ;
- sous chaque réponse : le **temps de traitement**, la liste des **sources** utilisées, un bouton « **Régénérer** » et les boutons de **feedback** (pouce levé / pouce baissé) ;
- une **zone de saisie** en bas d'écran, avec bouton de paramètres (icône curseurs), champ de texte multi-lignes et bouton d'envoi (qui se transforme en bouton d'arrêt — icône carré — pendant la génération de la réponse).




Figure 5.6: Fenêtre de discussion avec une réponse et ses sources

5.4.3 Carte de source

Chaque source citée sous une réponse de l'IA est présentée sous forme de carte dépliable, indiquant le titre du document, un extrait pertinent et un score de pertinence. Deux icônes d'action sont disponibles :

- une icône **œil**, ouvrant la fenêtre de prévisualisation du document (section 5.4.4) ;
- une icône **flèche vers le bas**, déclenchant le téléchargement du document original.

5.4.4 Fenêtre de prévisualisation de document

Une fenêtre modale centrale (*overlay*), fermable par la touche Échap, par un clic à l'extérieur ou par le bouton de fermeture, affichant le document original selon son format :

- **PDF** : affichage intégré natif du navigateur ;

- **Image** : affichage direct ;
- **Texte (.txt)** : contenu brut dans une zone de lecture ;
- **DOCX** : conversion en un rendu HTML lisible.

Un bouton « **Télécharger** » est également disponible dans l'en-tête de cette fenêtre.




Figure 5.7: Fenêtre de prévisualisation d'un document PDF

Cas particulier. Pour un document indexé avant la mise en place du stockage des fichiers originaux, la fenêtre affiche le message : « *Aucun aperçu disponible pour ce document.* »

5.5 Pages d'authentification

Les pages *Connexion* (/login) et *Créer un compte* (/register) présentent chacune un formulaire simple (nom d'utilisateur, mot de passe), un bouton de validation et un lien de bascule vers l'autre formulaire. Voir le chapitre 4 pour le détail du fonctionnement.

5.6 Pages secondaires

Les pages *Axes & Unités*, *Membres*, *Actualités*, *À propos* et *Contact* constituent la vitrine institutionnelle du site. Elles ne font pas partie du périmètre fonctionnel du RAG et ne sont donc pas détaillées davantage dans ce manuel.

Chapitre 6

Guide d'utilisation pas à pas

6.1 Se connecter

1. Ouvrir la page `/login`.
2. Saisir son nom d'utilisateur et son mot de passe.
3. Cliquer sur « *Se connecter* ».

6.2 Naviguer dans l'application

Une fois connecté, deux zones principales sont accessibles depuis la barre de navigation : la page *Publications* (gestion documentaire, voir section 5.3) et l'*espace de discussion* (section 5.4), accessible via l'URL `/chat`.

6.3 Ajouter (*upload*) un document

1. Se rendre sur la page *Publications*.
2. Dans le panneau d'upload, choisir le **mode de traitement** (Réfléchi ou Instantané).
3. Cliquer sur la zone de dépôt et sélectionner un fichier (`.pdf`, `.txt` ou `.docx`, 20 Mo maximum).
4. Patienter pendant le traitement : une barre de progression s'affiche en mode Instantané pour les fichiers PDF (avancement page par page).
5. À la fin du traitement, un message de confirmation indique le nombre de segments (*chunks*) créés.

Message de succès type : « *Document indexé avec succès : N chunks créés.* »

6.4 Indexation

L'indexation est **entièrement automatique** dès qu'un document est déposé : aucune action supplémentaire n'est requise de la part de l'utilisateur. Le détail technique du processus est décrit au chapitre 7.

6.5 Rechercher et poser une question

1. Se rendre dans l'espace de discussion (`/chat`) ou utiliser le panneau de recherche de la page *Publications*.
2. Saisir une question en langage naturel dans le champ de saisie.
3. Valider avec la touche Entrée (ou le bouton d'envoi).
4. Patienter pendant la génération de la réponse, affichée progressivement à l'écran.

6.6 Consulter les sources d'une réponse

Chaque réponse générée par l'IA affiche, juste en dessous, la liste des documents utilisés pour la construire. Cliquer sur une carte de source permet de la déplier et d'afficher l'extrait exact utilisé, ainsi que le score de pertinence associé.

6.7 Télécharger un document

Deux points d'accès permettent de télécharger le document **original tel qu'uploadé** (et non un texte reconstitué) :

- l'icône de téléchargement sur une carte de source, dans le chat ;
- l'icône de téléchargement dans le tableau de la bibliothèque documentaire.

6.8 Prévisualiser un document

Cliquer sur le titre d'un document (dans la bibliothèque) ou sur l'icône œil (bibliothèque ou carte de source) ouvre la fenêtre de prévisualisation décrite au section 5.4.4, sans quitter la page en cours.

6.9 Gérer son profil

Le profil (avatar et nom d'utilisateur) est visible en permanence en bas de la barre latérale de conversations. La déconnexion s'effectue depuis ce même emplacement.

6.10 Consulter l'historique des conversations

Toutes les conversations précédentes sont listées dans la barre latérale, regroupées par période. Il est possible de :

- rechercher une conversation par mot-clé ;
- épingler une conversation importante en haut de la liste ;
- renommer ou supprimer une conversation existante.

6.11 Administration

Fonctionnalité absente à ce jour. La plateforme ne propose actuellement aucun écran d'administration dédié (pas de gestion des comptes ni de tableau de bord global) : chaque utilisateur gère uniquement ses propres conversations, la bibliothèque documentaire étant quant à elle partagée entre tous les utilisateurs authentifiés.

Chapitre 7

Fonctionnement du RAG

Ce chapitre explique, de manière simple, le fonctionnement interne du pipeline RAG de CERVARENT AI, tel qu'implémenté dans le code du projet (services `FileUploadService`, `EmbeddingService` et `RagService`).

7.1 Vue d'ensemble du pipeline




Figure 7.1: Schéma du pipeline RAG complet, de l'upload à la réponse

Le traitement d'un document se déroule en cinq étapes séquentielles, détaillées ci-après : upload, découpage en segments, vectorisation, indexation, puis — au moment d'une question — recherche et génération.

7.2 Étape 1 : Upload et extraction du texte

Lorsqu'un fichier est déposé, deux opérations sont réalisées :

- le fichier **original** est envoyé tel quel vers **Supabase Storage**, pour permettre son téléchargement et sa prévisualisation ultérieurs ;
- son **contenu textuel** est extrait, selon son format (`.pdf`, `.txt`, `.docx`).

7.3 Étape 2 : Découpage en segments (*chunking*)

Le texte extrait est trop long pour être transmis en une seule fois au modèle d'IA : il est découpé en segments (*chunks*) de taille maîtrisée. Dans l'implémentation actuelle :

- chaque segment mesure **1500 caractères** ;
- un **chevauchement de 100 caractères** est conservé entre deux segments consécutifs, afin de ne pas couper une idée en plein milieu et de préserver le contexte à la frontière de deux segments.

Pourquoi découper le texte ? Un modèle d'embedding transforme un texte en un vecteur numérique de taille fixe : plus le texte est long, moins ce vecteur représente fidèlement chaque détail. Des segments courts et ciblés donnent une recherche plus précise.

7.4 Étape 3 : Vectorisation (*embeddings*)

Chaque segment de texte est transformé en un **vecteur numérique** (une liste de nombres) grâce au modèle d'embedding `mistral-embed` de Mistral AI. Ce vecteur représente le *sens* du texte : deux segments au contenu proche produisent des vecteurs numériquement proches. Pour optimiser les appels réseau, les segments sont envoyés à l'API par lots (*batches*) de 10.

7.5 Étape 4 : Indexation

Chaque segment, accompagné de son vecteur, de sa source (nom de fichier) et de son numéro d'ordre, est enregistré dans la table `document_chunks` de la base PostgreSQL. Cette table utilise l'extension

pgvector, qui permet à PostgreSQL de stocker des vecteurs et d'effectuer des comparaisons mathématiques entre eux directement en base de données.

7.6 Étape 5 : Recherche vectorielle

Lorsqu'un utilisateur pose une question :

1. la question elle-même est transformée en vecteur, exactement comme un segment de document (même modèle **mistral-embed**) ;
2. ce vecteur est comparé à tous les vecteurs déjà indexés, à l'aide d'une mesure de **distance cosinus** (opérateur `<=>` de **pgvector**) ;
3. les segments les plus proches (les plus similaires) sont sélectionnés, dans la limite du nombre paramétré par l'utilisateur (*topK*, réglable entre 1 et 8 depuis les paramètres du chat) ;
4. un **filtre de pertinence** écarte les segments dont la distance dépasse un seuil configuré (0.55 par défaut), afin d'éviter de renvoyer des segments hors-sujet lorsque peu de documents pertinents existent réellement.

7.7 Étape 6 : Génération de la réponse

Les segments retenus sont assemblés pour former un **contexte documentaire**, inséré dans une instruction système envoyée au modèle de langage **mistral-medium**, accompagné de l'historique récent de la conversation (jusqu'à 6 échanges) et de la question posée. Le modèle est explicitement instruit de :

- répondre **uniquement** à partir du contexte fourni, sans faire appel à des connaissances externes ;
- indiquer clairement l'absence d'information si aucun document pertinent ne permet de répondre ;
- citer naturellement les documents utilisés, sans exposer les détails techniques internes (segments, vecteurs, scores).

La réponse est ensuite renvoyée au frontend, soit d'un seul bloc, soit **progressivement** (mode « streaming », via des événements *Server-Sent Events*), ce qui permet à l'utilisateur de voir le texte s'afficher au fur et à mesure de sa génération, comme pour la plupart des assistants IA modernes.

7.8 Score de pertinence affiché

Le score affiché à côté de chaque source correspond à $1 - \text{distance cosinus}$: plus il est proche de 1 (soit 100 %), plus le segment est jugé pertinent par rapport à la question posée.

Chapitre 8

Messages système

Ce chapitre recense les principaux messages affichés par l'application, classés par catégorie.

8.1 Messages de succès

- « *Document indexé avec succès : N chunks créés.* » — fin d'un upload en mode Réfléchi.
- « *Merci pour votre retour* » — confirmation après avoir évalué une réponse de l'IA (pouce levé/baissé).

8.2 Messages d'erreur

- « *Ce nom d'utilisateur est déjà pris.* » — lors d'une tentative de création de compte avec un identifiant existant.
- « *Identifiants incorrects.* » — lors d'une tentative de connexion avec un mauvais mot de passe ou identifiant.
- « *Échec de l'upload. Vérifiez le format (PDF, TXT, DOCX) et la taille (max 20 Mo).* » — lorsqu'un fichier déposé ne peut être traité.
- « *Échec du téléchargement. Réessayez.* » — en cas d'erreur réseau pendant le téléchargement d'un document.
- « *Une erreur est survenue pendant le chargement de l'aperçu.* » — en cas d'échec de la fenêtre de prévisualisation.
- « *Aucun aperçu disponible pour ce document.* » — lorsque le fichier original n'a pas été conservé (document indexé avant la mise en place du stockage des originaux).
- « *Je n'ai trouvé aucun document pertinent pour répondre à cette question.* » — réponse renvoyée par l'IA lorsque aucun segment indexé ne dépasse le seuil de pertinence.

8.3 Messages de validation

Les formulaires de connexion et de création de compte utilisent la validation native du navigateur (champs **required**) : un champ vide empêche la soumission du formulaire et affiche une invite du navigateur invitant à le compléter.

8.4 Messages / indicateurs de chargement

- « *Connexion...* » — affiché sur le bouton de connexion pendant la vérification des identifiants.
- **Barre de progression page par page** — affichée pendant l'indexation d'un PDF en mode Instantané.
- « *Chargement de l'aperçu...* » — pendant la récupération du document pour la fenêtre de prévisualisation.
- « *Préparation de votre espace de discussion...* » — très brièvement affiché à l'ouverture de l'espace de chat, le temps d'initialiser la première conversation.
- **Indicateur de génération en cours** — le bouton d'envoi du chat se transforme en bouton d'arrêt (icône carrée) pendant la génération d'une réponse par l'IA.

Chapitre 9

Bonnes pratiques

9.1 Conseils d'utilisation

- Formuler des questions **précises et contextualisées** : plus une question est spécifique, plus les segments retrouvés par la recherche vectorielle seront pertinents.
- Utiliser l'**historique de conversation** pour poser des questions de suivi (« et pour les autres ? », « peux-tu développer ? ») : le contexte des échanges précédents est automatiquement transmis à l'IA (jusqu'à 6 tours d'historique).
- Vérifier systématiquement les **sources citées** sous chaque réponse avant de considérer une information comme fiable.
- Ajuster le paramètre *topK* (nombre de sources considérées) selon le besoin : une valeur faible pour une réponse ciblée, une valeur plus élevée pour une vision plus large du corpus documentaire.

9.2 Sécurité

- Ne jamais partager son mot de passe ni le jeton de session affiché dans les outils de développement du navigateur.
- Se déconnecter systématiquement après utilisation sur un poste partagé.
- Les administrateurs techniques du système doivent veiller à ne jamais exposer publiquement la clé `service_role` de Supabase ni la clé d'API Mistral AI, qui donnent un accès complet aux ressources associées.
- Régénérer périodiquement la clé secrète de signature des jetons JWT (`app.jwt.secret`) sur les environnements de production.

9.3 Gestion des documents

- Privilégier des documents **correctement structurés** (titres, paragraphes distincts) : la qualité du découpage en segments en dépend directement.
- Éviter d'indexer plusieurs fois un même document sous des noms différents, ce qui multiplierait inutilement les segments et pourrait diluer la pertinence des résultats.
- Supprimer les documents obsolètes ou incorrects de la bibliothèque pour éviter qu'ils ne soient cités par erreur dans une réponse.
- Privilégier le mode **Instantané** pour les documents volumineux, afin de ne pas bloquer l'interface pendant tout le traitement.

9.4 Gestion des comptes

- Choisir un mot de passe suffisamment robuste dès la création du compte (aucune récupération de mot de passe n'étant disponible en cas d'oubli, voir chapitre 4).
- Conserver précieusement ses identifiants : en l'absence de fonctionnalité de réinitialisation, la perte du mot de passe implique la création d'un nouveau compte.

Chapitre 10

Dépannage

Ce chapitre regroupe, sous forme de questions-réponses, les problèmes les plus fréquemment rencontrés.

10.1 Impossible de se connecter

Symptôme. Le message « *Identifiants incorrects* » apparaît systématiquement.

Solutions :

- Vérifier l'orthographe exacte du nom d'utilisateur (sensible à la casse).
- Vérifier que le compte a bien été créé au préalable (onglet « *Créer un compte* »).
- Vérifier que le backend est bien démarré et accessible sur le port 8087.

10.2 Erreur PostgreSQL

Symptôme. Le backend ne démarre pas, avec une erreur de connexion à la base de données dans les journaux (logs).

Solutions :

- Vérifier les propriétés `spring.datasource.url`, `username` et `password` dans `application.properties`.
- Vérifier que le script `schema.sql` a bien été exécuté sur la base cible.
- Vérifier que l'extension `pgvector` est activée sur le projet Supabase.

10.3 Erreur Supabase (Storage)

Symptôme. Le message « *Impossible d'enregistrer le document original dans Supabase Storage* » apparaît lors d'un upload.

Solutions :

- Vérifier que la propriété `supabase.service-role-key` contient bien la clé `service_role` (et non la clé `anon`).
- Vérifier que le bucket indiqué dans `supabase.storage.bucket` existe bien dans le projet Supabase.
- Vérifier la validité de l'URL `supabase.url` (sans slash final).

10.4 Erreur d'upload de document

Symptôme. Le message « *Échec de l'upload* » s'affiche.

Solutions :

- Vérifier que le fichier est bien au format `.pdf`, `.txt` ou `.docx`.
- Vérifier que la taille du fichier ne dépasse pas 20 Mo.
- Réessayer en mode *Instantané* si le mode *Réfléchi* échoue sur un document volumineux (risque de dépassement de délai).

10.5 Erreur liée à l'IA (Mistral)

Symptôme. Les réponses ne se génèrent pas, ou une erreur apparaît pendant le streaming de la réponse.

Solutions :

- Vérifier la validité de la clé `spring.ai.mistralai.api-key`.
- Vérifier que le quota d'utilisation de l'API Mistral AI n'est pas dépassé.
- Consulter les journaux du backend (niveau `DEBUG` activé par défaut sur `org.springframework.ai`) pour identifier la cause précise.

10.6 Erreur d'appel API (404 / 401 / 500)

Solutions :

- **401 Non autorisé** : le jeton JWT a expiré (durée de vie de 24h) ou est absent — se reconnecter.
- **404 Introuvable** : vérifier l'URL appelée, notamment que le backend tourne bien sur le port 8087.
- **500 Erreur serveur** : consulter les journaux du backend pour identifier la cause exacte (base de données, IA, stockage).

10.7 Erreur côté React (frontend)

Solutions :

- Vérifier que les dépendances ont bien été installées (`npm install`) avant le lancement.
- Vider le cache du navigateur en cas d'affichage incohérent après une mise à jour du frontend.
- Consulter la console du navigateur (outils de développement) pour identifier une éventuelle erreur JavaScript précise.

10.8 Erreur côté Spring Boot (backend)

Solutions :

- Vérifier que la version de Java installée est bien la 17 ou supérieure (`java -version`).
- Relancer une compilation propre avec `./mvnw clean install` en cas d'erreur de compilation persistante.
- Vérifier qu'aucun autre processus n'utilise déjà le port 8087.

10.9 Docker

Fonctionnalité absente à ce jour. Le projet ne fournit actuellement aucune configuration Docker (pas de `Dockerfile` ni de `docker-compose.yml`) : l'installation et le lancement s'effectuent nativement avec Maven et npm, comme décrit au chapitre 3.

Annexe A

Glossaire

Chunk (segment)

Fragment de texte issu du découpage d'un document, de taille limitée (1500 caractères dans CERVARENT AI), utilisé comme unité de base pour l'indexation et la recherche.

Embedding

Représentation numérique (vecteur) d'un texte, produite par un modèle d'intelligence artificielle, permettant de comparer mathématiquement le sens de deux textes.

JWT (JSON Web Token)

Jeton d'authentification signé, transmis par le client à chaque requête pour prouver son identité sans avoir à renvoyer le mot de passe.

LLM (Large Language Model)

Grand modèle de langage, capable de générer du texte à partir d'une instruction (*prompt*).

pgvector

Extension de PostgreSQL ajoutant un type de donnée vectoriel et des opérateurs de calcul de distance entre vecteurs.

Prompt

Instruction textuelle envoyée à un modèle de langage pour orienter sa réponse.

RAG (Retrieval-Augmented Generation)

Architecture combinant une recherche documentaire et une génération de texte par IA, pour produire des réponses ancrées dans des documents réels.

Score de pertinence

Indicateur (entre 0 et 1) mesurant la proximité entre un segment de document et une question posée.

Streaming

Mode de transmission d'une réponse fragment par fragment, au fur et à mesure de sa génération, plutôt qu'en un seul bloc final.

Supabase Storage

Service de stockage de fichiers fourni par Supabase, utilisé pour conserver les documents originaux uploadés.

Annexe B

Liste des acronymes

Table B.1: Liste des acronymes utilisés dans ce manuel

Acronyme	Signification
API	Application Programming Interface
CRUD	Create, Read, Update, Delete
IA	Intelligence Artificielle
JDBC	Java Database Connectivity
JWT	JSON Web Token
LLM	Large Language Model
RAG	Retrieval-Augmented Generation
REST	Representational State Transfer
SSE	Server-Sent Events
SQL	Structured Query Language
UI/UX	User Interface / User Experience

Architecture simplifiée

Le figure C.1 synthétise l’architecture globale de la plateforme CERVARENT AI.




Figure C.1: Schéma d’architecture simplifiée (Frontend React – Backend Spring Boot – PostgreSQL/pgvector – Supabase Storage – API Mistral AI)

Table C.1: Rôle de chaque composant de l’architecture

Composant	Rôle
React (frontend)	Interface utilisateur, gestion de l’état des conversations, appels à l’API REST du backend
Spring Boot (back-end)	Exposition de l’API REST, orchestration du pipeline RAG, sécurité JWT
PostgreSQL + pgvector	Stockage des segments indexés et de leurs vecteurs, recherche par similarité
Supabase Storage	Stockage des fichiers originaux (PDF, DOCX, TXT, images)
API Mistral AI	Génération des embeddings et des réponses en langage naturel

Bibliographie

- [1] Spring Team, *Spring Boot Reference Documentation*, <https://docs.spring.io/spring-boot/>, consulté en 2026.
- [2] Spring Team, *Spring AI Reference Documentation*, <https://docs.spring.io/spring-ai/reference/>, consulté en 2026.
- [3] pgvector contributors, *pgvector: Open-source vector similarity search for Postgres*, <https://github.com/pgvector/pgvector>, consulté en 2026.
- [4] Supabase Inc., *Supabase Documentation*, <https://supabase.com/docs>, consulté en 2026.
- [5] Mistral AI, *Mistral AI API Documentation*, <https://docs.mistral.ai/>, consulté en 2026.
- [6] Meta Open Source, *React Documentation*, <https://react.dev/>, consulté en 2026.
- [7] P. Lewis *et al.*, *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*, Advances in Neural Information Processing Systems (NeurIPS), 2020.